

금융 AI 리터러시

머신러닝 구조와 학습 방식 이해



머신러닝의 기본 개념





변수의 설명력



변수 r 은 결과값을
설명하는 데 영향을 미침



Q

머신러닝에서

변수는 결과값을

얼마나 잘 설명할 수 있을까?

머신러닝이 하는 일 : 관계 학습과 예측



↳ 변수란 무엇인가

독립변수

예측 대상에 영향을 주는 이미 알고 있는 정보

종속변수


예측하고 싶은 결과

독립변수(x)	종속변수(y)
Feature	Target
Independent	Dependent
input	output
regressor	regressand
predictor	predicted
explanatory	explained
exogenous	endogenous
manipulated	measured
exposure	outcome



“머신러닝” 용어 창시자

컴퓨터가 명시적으로 프로그래밍되지 않아도
학습할 수 있도록 하는 연구 분야



Arthur L. Samuel

컴퓨터가 데이터 기반으로
규칙을 찾아내고 문제를 해결할 수 있음

“학습” 정의 체계화

작업이 경험을 통해
성능이 향상된다면 학습이 이루어진 것



Tom Michael Mitchell

작업 : T
경험 : E
성능 측정 방법 : P



작업(T)

달성하고자 하는 작업

예 이메일 스팸 분류, 고객의 대출 상환 가능성 예측

경험(E)

과거 관찰된 데이터

예 스팸 여부가 기록된 이메일 수천 건

성능 측정 방법 (P)

예측 정확도, 오차율, 손실 함수 등을 통해
학습의 결과를 수치로 평가하는 방법

예 전체 이메일 중에서 올바르게 분류한 비율,
스팸이라고 예측한 것 중 실제로 스팸인 비율



Machine Learning

머신러닝은 **작업을 수행하면서 경험을 통해** **성능이 향상되는 과정**

머신러닝 학습방식의 종류와 구조





대표적인 3가지 학습방식

지도학습

비지도학습

강화학습



머신러닝 학습방식의 종류와 구조

머신러닝의 학습방식의 종류

지도학습

(Supervised Learning)

‘정답이 있는 데이터’를 학습하는 방식



현재 가장 주류의 연구 분야



비지도학습 (Unsupervised Learning)

정답이 없는 데이터에서
구조나 패턴을 발견하는 학습 방식

예) 클러스터링(군집화)



데이터를 얻기 어려울 때
전처리 단계에서 많이 사용됨




강화학습

(Reinforcement Learning)

정해진 정답 없이 보상을 최대화하도록
피드백을 기반으로 하는 학습방식

예 자율 비행, 게임 플레이, 로봇 제어




강화학습과 지도학습을 결합한
모방학습(Imitation Learning)에 대한
연구가 진행되고 있음



지도학습 (Supervised Learning)

‘정답이 있는 데이터’를 학습하는 방식





분류(Classification) vs 회귀(Regression)

항목	분류	회귀
예측 대상	클래스 라벨	연속된 숫자
출력 형태	범주형(Categorical)	수치형(Numerical)
문제 예시	암 진단, 고객 이탈 예측	집값 예측, 기온 예측
모델 예시	로지스틱 회귀, SVM	선형 회귀, SVR
평가지표	정확도, F1-score 등	MSE, R^2 등



분류란 **‘무엇인가’**를 맞추는 문제



회귀란

‘값이 얼마인지’ 맞추는 문제



분류 예제






회귀 예제






지도학습의 학습구조






지도학습의 학습구조





K-means 클러스터링


- ◇ 정답이 없는 데이터를 다루는 비지도학습으로 자동으로 데이터를 군집화(Clustering)하는 방법
- ◇ K-means 클러스터링 진행 단계
 - ① K개의 클러스터 개수 설정 후 데이터 중 무작위로 K개의 중심(Centroid) 초기화





K-means 클러스터링


- ◇ 정답이 없는 데이터를 다루는 비지도학습으로 자동으로 데이터를 군집화(Clustering)하는 방법
- ◇ K-means 클러스터링 진행 단계
 - ② 각 데이터를 가장 가까운 중심점에 할당하여 군집 형성







K-means 클러스터링

- ◇ 정답이 없는 데이터를 다루는 비지도학습으로 자동으로 데이터를 군집화(Clustering)하는 방법
- ◇ K-means 클러스터링 진행 단계
 - ③ 각 클러스터에 대해 그 안의 데이터의 평균 위치를 계산하여 새로운 중심점(Centroid) 구하고 중심점의 위치가 바뀌지 않을 때까지 클러스터 할당 반복




더이상 변화가
없을 때까지 반복






무작위의 개와 고양이의 사진


임베딩
→



개




고양이





강화학습 (Reinforcement Learning)

정해진 정답 없이 보상을 최대화하도록
피드백을 기반으로 하는 학습방식





AlphaGo-Zero

모델
구축

AlphaGo-Zero의
바둑두기

무작위로
바둑을 둬م

게임 결과

이겼을 경우
보상을 받음

게임 과정
복기 및 학습

‘어떤 수가 좋은 결과를
가져왔는지’ 반복 학습

게임 반복

- ◇ 정책망: 유리한 수 판단
- ◇ 가치망: 승률을 예측



AlphaGo-Zero

실전
운영

정책망 기반의
유망한 수 제안

MCTS 기반의
시뮬레이션 수행

가치망의
미래 승률 예측

가치가 가장
높은 수 선택

MCTS: 가장 유리한 수 선택

머신러닝의 실제 활용





단계	핵심 내용	주요 도구 및 기법 예시
문제 정의	예측, 분류, 추천 등 목적 및 성공 지표 설정	KPI 분석, 문제 포물레이션
데이터 수집	원시 데이터 확보, API 호출, 크롤링 등	SQL, Python API, Scrapy
데이터 전처리	결측치 제거, 정규화, 범주형 인코딩 등	Pandas, Scikit-learn, FeatureTools
피처 엔지니어링	도메인 지식 기반의 유용한 특징 생성	PCA, one-hot, embedding
모델 선택 및 학습	알고리즘 결정 및 훈련	Scikit-learn, XGBoost, PyTorch, TensorFlow
모델 평가	정확도, 정밀도, 재현율, AUC 등의 지표 계산	Cross-validation, confusion matrix
매개변수 튜닝	성능 향상을 위한 파라미터 최적화	Grid Search, Optuna, Hyperopt
모델 배포	실제 시스템에 통합	Flask, FastAPI, Docker, MLflow
운영 및 모니터링	예측 품질, Drift 감지, 자동 재학습 등	Prometheus, Grafana, Evidently, Airflow



단계	핵심 내용	주요 도구 및 기법 예시
▶ 문제 정의	예측, 분류, 추천 등 목적 및 성공 지표 설정	KPI 분석, 문제 포물레이션
데이터 수집	원시 데이터 확보, API 호출, 크롤링 등	SQL, Python API, Scrapy
데이터 전처리	결측치 제거, 정규화, 범주형 인코딩 등	Pandas, Scikit-learn, FeatureTools
피처 엔지니어링	도메인 지식 기반의 유용한 특징 생성	PCA, one-hot, embedding
모델 선택 및 학습	알고리즘 결정 및 훈련	Scikit-learn, XGBoost, PyTorch, TensorFlow
모델 평가	정확도, 정밀도, 재현율, AUC 등의 지표 계산	Cross-validation, confusion matrix
매개변수 튜닝	성능 향상을 위한 파라미터 최적화	Grid Search, Optuna, Hyperopt
모델 배포	실제 시스템에 통합	Flask, FastAPI, Docker, MLflow
운영 및 모니터링	예측 품질, Drift 감지, 자동 재학습 등	Prometheus, Grafana, Evidently, Airflow



단계	핵심 내용	주요 도구 및 기법 예시
문제 정의	예측, 분류, 추천 등 목적 및 성공 지표 설정	KPI 분석, 문제 포물레이션
데이터 수집	원시 데이터 확보, API 호출, 크롤링 등	SQL, Python API, Scrapy
데이터 전처리	결측치 제거, 정규화, 범주형 인코딩 등	Pandas, Scikit-learn, FeatureTools
피처 엔지니어링	도메인 지식 기반의 유용한 특징 생성	PCA, one-hot, embedding
모델 선택 및 학습	알고리즘 결정 및 훈련	Scikit-learn, XGBoost, PyTorch, TensorFlow
모델 평가	정확도, 정밀도, 재현율, AUC 등의 지표 계산	Cross-validation, confusion matrix
매개변수 튜닝	성능 향상을 위한 파라미터 최적화	Grid Search, Optuna, Hyperopt
모델 배포	실제 시스템에 통합	Flask, FastAPI, Docker, MLflow
운영 및 모니터링	예측 품질, Drift 감지, 자동 재학습 등	Prometheus, Grafana, Evidently, Airflow



단계	핵심 내용	주요 도구 및 기법 예시
문제 정의	예측, 분류, 추천 등 목적 및 성공 지표 설정	KPI 분석, 문제 포مول레이션
데이터 수집	원시 데이터 확보, API 호출, 크롤링 등	SQL, Python API, Scrapy
데이터 전처리	결측치 제거, 정규화, 범주형 인코딩 등	Pandas, Scikit-learn, FeatureTools
피처 엔지니어링	도메인 지식 기반의 유용한 특징 생성	PCA, one-hot, embedding
모델 선택 및 학습	알고리즘 결정 및 훈련	Scikit-learn, XGBoost, PyTorch, TensorFlow
모델 평가	정확도, 정밀도, 재현율, AUC 등의 지표 계산	Cross-validation, confusion matrix
매개변수 튜닝	성능 향상을 위한 파라미터 최적화	Grid Search, Optuna, Hyperopt
모델 배포	실제 시스템에 통합	Flask, FastAPI, Docker, MLflow
운영 및 모니터링	예측 품질, Drift 감지, 자동 재학습 등	Prometheus, Grafana, Evidently, Airflow



단계	핵심 내용	주요 도구 및 기법 예시
문제 정의	예측, 분류, 추천 등 목적 및 성공 지표 설정	KPI 분석, 문제 포물레이션
데이터 수집	원시 데이터 확보, API 호출, 크롤링 등	SQL, Python API, Scrapy
데이터 전처리	결측치 제거, 정규화, 범주형 인코딩 등	Pandas, Scikit-learn, FeatureTools
피처 엔지니어링	도메인 지식 기반의 유용한 특징 생성	PCA, one-hot, embedding
모델 선택 및 학습	알고리즘 결정 및 훈련	Scikit-learn, XGBoost, PyTorch, TensorFlow
모델 평가	정확도, 정밀도, 재현율, AUC 등의 지표 계산	Cross-validation, confusion matrix
매개변수 튜닝	성능 향상을 위한 파라미터 최적화	Grid Search, Optuna, Hyperopt
모델 배포	실제 시스템에 통합	Flask, FastAPI, Docker, MLflow
운영 및 모니터링	예측 품질, Drift 감지, 자동 재학습 등	Prometheus, Grafana, Evidently, Airflow



머신러닝은
모델 개발에 그치지 않고
문제 정의부터 운영까지의
전체 과정을 이해하는 것이 중요함