

금융 AI리터러시

딥러닝 및 자연어처리 이해



딥러닝의 기본 개념





딥러닝 (Deep Learning)

인공지능의 한 분야이며 머신러닝의 한 기법으로,
인공신경망을 다층으로 쌓아 구성한
심층 신경망을 통해 데이터를 학습할 수 있는 기술
→ 모델이 스스로 패턴을 뽑아 냄



↳ 딥러닝의 정의

핵심요소	설명
신경망 (Neural Network)	인간의 뇌 신경세포(뉴런)를 모방한 수학적 모델로 입력, 은닉층, 출력층으로 구성됨
다층 퍼셉트론 (MLP)	입력층과 여러 개의 은닉층, 출력층으로 이루어진 구조
활성화 함수 (Activation Function)	비선형성을 도입하여 복잡한 함수 근사를 가능하게 함 예 ReLU, Sigmoid 등
역전파 (Backpropagation)	오차를 출력층에서 입력층 방향으로 전파하여 가중치를 업데이트하는 알고리즘
최적화 알고리즘 (Optimizer)	손실 함수 값을 최소화하기 위한 가중치 조정 방식 예 SGD, Adam 등
손실 함수 (Loss Function)	예측값과 실제값 간의 오차 측정 지표 예 MSE, Cross Entropy 등



1980년대
초반

존 흘필드의
순환 신경망 모델 제안

1986~
1990년대
초반

BPTT(Back Propagation Through Time) 방법을 통한
RNN(Recurrent Neural Net) 훈련 및
LSTM과 GRU의 등장으로 RNN 발전

데이비드 러멜하트, 제프리 힌튼 등에 의해 제안
및 기울기 소멸 문제 해결




RNN

이전 상태의 정보를 현재 상태로 전달할 수 있도록 설계된
신경망 구조로, 순차 데이터를 처리하는 데 강점을 가짐

$$h_t = f(W \cdot x_t + U \cdot h_{t-1} + b)$$

x_t : 현재 입력 W, U : 가중치 행렬
 h_{t-1} : 이전 상태 f : 활성화 함수





RNN

***RNN*은**

**딥러닝에서 기억의 시작을
가능하게 한 출발점**



분야	적용 예시	
컴퓨터 비전	◇ 얼굴 인식	◇ 자율주행
	◇ 객체 탐지	
자연어 처리 (NLP)	◇ 질문응답 시스템	◇ 감정 분석
	◇ 번역기	
음성 처리	◇ 음성 인식	◇ 자동 자막 생성
	◇ 음성 합성	◇ 보이스봇
추천 시스템	◇ 사용자 행동 기반 추천	
	◇ 콘텐츠 필터링	
의료	◇ 질병 진단	◇ 유전자 분석
	◇ MRI 분석	
로보틱스	◇ 로봇 제어	
	◇ 강화학습 기반의 경로 탐색	



모델	구조 개요	주요 특징 및 용도
MLP (Multilayer Perceptron)	완전 연결층 (Fully Connected Layers)으로 구성	◇ 가장 기본적인 신경망 구조 ◇ 고정된 입력 데이터를 다루는 분류, 회귀 문제, 구조화된 데이터 분석과 기초 벤치마크 용도에 활용됨
CNN (Convolutional Neural Network)	Conv → ReLU → Pooling 층의 반복 후 FC층	◇ 합성곱과 풀링 층을 반복해 이미지나 공간 정보를 추출하는 구조 ◇ 이미지 분류, 객체 탐지, 의료 영상 분석, 자율 주행 등에 활용됨
RNN (Recurrent Neural Network) / LSTM (Long Short-Term Memory)	은닉 상태를 시간축에 따라 순환 연결 (LSTM: 게이트 추가)	◇ 순차적인 시퀀스, 시계열 데이터를 다룰 때 활용됨 ◇ 텍스트 생성, 음성 인식 등 자연어 처리 응용에 사용됨 예 Seq2Seq



모델	구조 개요	주요 특징 및 용도
▶ MLP (Multilayer Perceptron)	완전 연결층 (Fully Connected Layers)으로 구성	◇ 가장 기본적인 신경망 구조 ◇ 고정된 입력 데이터를 다루는 분류, 회귀 문제, 구조화된 데이터 분석과 기초 벤치마크 용도에 활용됨
CNN (Convolutional Neural Network)	Conv → ReLU → Pooling 층의 반복 후 FC층	◇ 합성곱과 풀링 층을 반복해 이미지나 공간 정보를 추출하는 구조 ◇ 이미지 분류, 객체 탐지, 의료 영상 분석, 자율 주행 등에 활용됨
RNN (Recurrent Neural Network) / LSTM (Long Short-Term Memory)	은닉 상태를 시간축에 따라 순환 연결 (LSTM: 게이트 추가)	◇ 순차적인 시퀀스, 시계열 데이터를 다룰 때 활용됨 ◇ 텍스트 생성, 음성 인식 등 자연어 처리 응용에 사용됨 예 Seq2Seq



모델	구조 개요	주요 특징 및 용도
MLP (Multilayer Perceptron)	완전 연결층 (Fully Connected Layers)으로 구성	◇ 가장 기본적인 신경망 구조 ◇ 고정된 입력 데이터를 다루는 분류, 회귀 문제, 구조화된 데이터 분석과 기초 벤치마크 용도에 활용됨
▶ CNN (Convolutional Neural Network)	Conv → ReLU → Pooling 층의 반복 후 FC층	◇ 합성곱과 풀링 층을 반복해 이미지나 공간 정보를 추출하는 구조 ◇ 이미지 분류, 객체 탐지, 의료 영상 분석, 자율 주행 등에 활용됨
RNN (Recurrent Neural Network) / LSTM (Long Short-Term Memory)	은닉 상태를 시간축에 따라 순환 연결 (LSTM: 게이트 추가)	◇ 순차적인 시퀀스, 시계열 데이터를 다룰 때 활용됨 ◇ 텍스트 생성, 음성 인식 등 자연어 처리 응용에 사용됨 예) Seq2Seq



모델	구조 개요	주요 특징 및 용도
MLP (Multilayer Perceptron)	완전 연결층 (Fully Connected Layers)으로 구성	◇ 가장 기본적인 신경망 구조 ◇ 고정된 입력 데이터를 다루는 분류, 회귀 문제, 구조화된 데이터 분석과 기초 벤치마크 용도에 활용됨
CNN (Convolutional Neural Network)	Conv → ReLU → Pooling 층의 반복 후 FC층	◇ 합성곱과 풀링 층을 반복해 이미지나 공간 정보를 추출하는 구조 ◇ 이미지 분류, 객체 탐지, 의료 영상 분석, 자율 주행 등에 활용됨
RNN (Recurrent Neural Network) / LSTM (Long Short-Term Memory)	은닉 상태를 시간축에 따라 순환 연결 (LSTM: 게이트 추가)	◇ 순차적인 시퀀스, 시계열 데이터를 다룰 때 활용됨 ◇ 텍스트 생성, 음성 인식 등 자연어 처리 응용에 사용됨 예 Seq2Seq



모델	구조 개요	주요 특징 및 용도
▶ Autoencoder	Encoder-Decoder 구조, 비지도 학습 방식	◇ 데이터 압축 및 중요한 특징을 추출하며, 입력을 다시 복원하는 구조로 활용됨 ◇ 데이터 전처리, 표현 학습, 잡음 제거 등에 사용됨
Transformer	Self-Attention 기반의 인코더·디코더 구조	시퀀스 병렬 처리, 문맥의 이해, 번역, 챗봇, 문서 요약 등에서 핵심적인 역할을 함



모델	구조 개요	주요 특징 및 용도
Autoencoder	Encoder-Decoder 구조, 비지도 학습 방식	◇ 데이터 압축 및 중요한 특징을 추출하며, 입력을 다시 복원하는 구조로 활용됨 ◇ 데이터 전처리, 표현 학습, 잡음 제거 등에 사용됨
▶ Transformer	Self-Attention 기반의 인코더·디코더 구조	시퀀스 병렬 처리, 문맥의 이해, 번역, 챗봇, 문서 요약 등에서 핵심적인 역할을 함



머신러닝(Machine Learning)

- ◇ 수동으로 특징을 설계(Feature Engineering) 및 추출한 뒤 그 특징을 기반으로 하는 학습구조

예 사람이 거래 금액·시간·지역 등을 직접 정의하여 입력값으로 사용하는 방식

- ◇ 적은 데이터에서 효과적으로 사용할 수 있으며 학습 시간이 비교적 짧음

- ◇ 사람의 지식과 경험의 의존도가 높으며 복잡한 패턴을 자동으로 찾는 데 한계가 있음

- ◇ 대표적인 모델

예 결정트리, SVM 등

딥러닝(Deep Learning)

- ◇ 다층 신경망을 통해 자동으로 특징 추출(End-to-End) 및 학습하는 구조

예 이미지 인식 문제에서 모델이 자동으로 사람의 얼굴 특징의 패턴을 찾아냄

- ◇ 대규모 데이터에서 효과적으로 사용되며 복잡한 문제를 해결 할 때 유용함

- ◇ 연산량이 많아 강력한 컴퓨팅 자원이 필요하며 내부 구조가 복잡하여 해석하기 어려움

- ◇ 대표적인 모델

예 신경망 기반 구조



머신러닝(Machine Learning)

- ◇ 수동으로 특징을 설계(Feature Engineering) 및 추출한 뒤 그 특징을 기반으로 하는 학습구조

예 사람이 거래 금액·시간·지역 등을 직접 정의하여 입력값으로 사용하는 방식

- ◇ 적은 데이터에서 효과적으로 사용할 수 있으며 학습 시간이 비교적 짧음
- ◇ 사람의 지식과 경험의 의존도가 높으며 복잡한 패턴을 학습하기 어렵다

**사람이 직접 설계한
특징 중심의 구조화된 접근법**

딥러닝(Deep Learning)

- ◇ 다층 신경망을 통해 자동으로 특징 추출(End-to-End) 및 학습하는 구조

예 이미지 인식 문제에서 모델이 자동으로 사람의 얼굴 특징의 패턴을 찾아냄

- ◇ 대규모 데이터에서 효과적으로 사용되며 복잡한 문제를 해결 할 때 유용함
- ◇ 연산량이 많아 강력한 컴퓨팅 자원이 필요하며 내부 구조가 복잡하여 해석이 어렵다

**자동으로 특징을 찾아내는
고도화된 학습 방식**



딥러닝의 한계

- ◇ 내부 구조가 복잡하고 매개변수의 수가 많기 때문에 해석 가능성이 부족함
→ 의료, 금융 등 신뢰성과 투명성이 중요한 분야에서는 더욱 신중하게 접근해야 함
- ◇ 데이터 의존성에 따른 성능 저하 및 판단 오류의 위험이 있음
- ◇ 방대한 계산량으로 인한 연산 자원 및 비용 부담이 큼
- ◇ 윤리적 문제가 중요한 과제로 떠오르고 있음
 - 예 데이터 개인정보 보호, 편향성과 차별 문제, 잘못된 정보 생성 등

자연어처리 기초






자연어처리 (NLP)

딥러닝의 대표적인 응용 분야 중 하나

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	q	r	s	t	u	v	w	x	y	z
x	y	z	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	q	r	s	t	u	v	w


시저 암호

ebiil ?





빈도 분석





자연어 처리 모델

- ◇ 단순한 문자 처리가 아닌 빈도와 문맥을 종합적으로 학습하여 자연스럽게 정확한 문장을 생성함
- ◇ 언어의 규칙성과 빈도는 자연어처리 기술의 핵심 원리가 됨



Q

**언어의 규칙성과 빈도 특성을
분석하고 모델에 학습시키기 위한
언어 데이터를 뭐라고 부를까?**

수집된 데이터의 집합: 말뭉치(Corpus)



1950~
1970년

최초의 전자 말뭉치 브라운 코퍼스 등장

- ◇ 미국 영어에 기반함
- ◇ 15개 장르의 500개의 표본을 포함함
- ◇ 100만 개의 단어로 구성됨
- ◇ 빈도계산과 통계적 언어 분석의 기반이 됨

1970~
2000년

컴퓨터 성능 향상으로 인한 대규모 말뭉치 등장

- ◇ 1970년대에 영국 영어 대상의 Lancaster-Oslo/Bergen(LOB) Corpus가 개발됨
- ◇ 1980년대에 영사전 개발을 위한 COBUILD 프로젝트가 진행됨
- ◇ 1990년대에 1억 단어로 구성된 British National Corpus(BNC)가 개발됨

2000년
이후

현대의 거대규모 말뭉치

- ◇ Google Ngram Viewer
: 16~21세기에 출판된 책의 대규모 N-gram 빈도 데이터를 활용함
- ◇ Common Crawl
: 웹 크롤링을 통한 텍스트 데이터를 BERT와 같은 현대 언어 모델 학습에 사용함
- ◇ OpenWebText
: 대규모 웹 텍스트 데이터셋으로 언어 모델 연구에 활용됨



말뭉치의 구성

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋

사용자 생성
데이터

Ai

Corpus



말뭉치의 구성

- ◇ 최신 정보와 다양한 주제를 담고 있어 자연어처리 모델을 학습시키는 데 유용함

예 Common Crawl,
Wikipedia Dump

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋

사용자 생성
데이터

Ai

Corpus



말뭉치의 구성

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋

사용자 생성
데이터

◇ 연구 및 실험에 널리 활용됨

예 Kaggle, Hugging Face,
Open Data

Corpus

Ai



말뭉치의 구성

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋

사용자 생성
데이터

◆ 특정 분야의 전문 모델을
학습할 때 필수적임

예 의료, 법률,
과학 논문(PubMed, arXiv 등)

Ai

Corpus



말뭉치의 구성

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋

사용자 생성
데이터

◆ 실제 사용자가 작성한
자연스러운 문장 패턴을 포함함

예 SNS 게시물, 리뷰 플랫폼

Corpus



말뭉치의 구성

웹 크롤링
데이터

공개
데이터셋

도메인 특화
데이터셋


사용자 생성
데이터

Ai

Corpus



↳ 전처리를 통한 말뭉치의 구성



원시 데이터 수집



데이터 정제 과정

- ◇ HTML 태그 제거
- ◇ 중복 제거
- ◇ 노이즈 필터링
- ◇ 언어 감지



단어 분리 과정

텍스트를 공백이나
구두점 기준으로
단어 단위로 분리



말뭉치 완성



1. 규칙 기반

- ◇ 핵심 아이디어: 사람이 정의한 언어 규칙
- ◇ 데이터 활용을 하지 않음
- ◇ 문맥 처리 능력이 제한적임
- ◇ 새로운 표현 처리가 불가함
- ◇ 사람이 이해하기 쉬우나 확장성이 부족함
- 예 규칙 기반 생성 문법



2. 통계 기반 N-gram

- ◇ 핵심 아이디어: 단어의 확률 분포 학습
- ◇ 단순 빈도와 확률 계산을 할 때 데이터를 활용함
- ◇ 짧은 문맥($N-1$)에 대한 처리가 가능함
- ◇ 새로운 표현 처리가 제한적임
- ◇ 간단하고 빠르게 계산할 수 있으나 희소성 문제와 문맥에 제한이 있음
- 예 N-gram, HMM



3. 데이터 기반 ML 모델

- ◇ 핵심 아이디어: 데이터 패턴의 학습
- ◇ 도메인에 특화된 중간 규모의 데이터셋을 활용함
- ◇ 도메인에 특화된 문장의 문맥 처리는 가능하나,
긴 문장의 문맥 처리에는 한계가 있음
- ◇ 데이터 품질에 따라 일반화 능력이 종속되어 있음
- 예 SVM, CRF (Conditional Random Field), Logistic Regression



4. 데이터 기반 신경망 모델

- ◇ 핵심 아이디어: 분산 표현과 신경망 기반의 언어 모델링
- ◇ 대규모 데이터를 활용한 복잡한 학습이 가능함
- ◇ 길고 복잡한 문장의 문맥 처리가 가능함
- ◇ 높은 수준의 일반화 능력을 지님
- ◇ 정확도가 높으나 계산 비용이 높고 블랙박스 모델의 한계가 있음
- 예 Word2Vec, RNN, Transformer

자연어처리 모델







Seq2Seq (Sequence-to-Sequence)

연속 시퀀스 데이터 처리를 위해 등장한 모델

시퀀스(Sequence)란 단어·문장처럼 순서가 중요한
데이터의 나열로 자연어처리(NLP)에서는
단어의 순서와 맥락이 의미를 결정하므로,
이를 처리하는 것이 핵심임

Encoder





Seq2Seq (Sequence-to-Sequence)


연속 시퀀스 데이터 처리를 위해 등장한 모델

- ◇ 입력과 출력이 모두 시퀀스 형태인 다양한 문제를 해결하는데 활용됨
 - 예 기계 번역, 챗봇, 문장 요약, 질문 답변 등
- ◇ 기존 RNN의 한계를 극복하여 문장의 의미를 하나의 벡터로 요약하여 벡터 기반의 새로운 시퀀스를 생성하는 혁신적인 모델



Seq2Seq with Attention

디코더가 인코더의 모든 hidden state(단어별 정보)를 참조하여
각 시점마다 필요한 정보에 집중(Attention)할 수 있도록 한
시퀀스 처리 모델





트랜스포머 (Transformer)

2017년 논문 “Attention is All You Need” (Vaswani et al.)에서
처음 제안된 기존 구조의 한계를 해결한 모델

- ◇ Self-Attention 메커니즘을 통해 학습하여 순차 처리 없이 병렬 연산이 가능함
- ◇ 입력 순서를 인코딩하기 위해 Positional Encoding이라는 기법을 사용하여
학습 속도와 성능이 크게 향상됨



포지셔널 인코딩(Positional Encoding)은 단어가 문장 안에서
몇 번째 위치에 있는지를 숫자 패턴으로 표시해 주는 기법

기본 구조	한계점	트랜스포머의 해결 방법
RNN, LSTM	순차적 처리 → 느림 장기의존성 문제	Attention 기반 병렬 처리 전 범위 의존성 처리 가능



트랜스포머 (Transformer)

2017년 논문 “Attention is All You Need” (Vaswani et al.)에서
처음 제안된 기존 구조의 한계를 해결한 모델

구성 요소	설명
Self-Attention	입력 시퀀스 내 단어 사이의 상호작용을 계산하여 문맥상 주목해야 하는 단어를 학습함
Multi-Head Attention	여러 개의 서로 다른 관점에서 동시에 관계를 학습하여 더 풍부한 문맥 표현을 제공함
Position Encoding	순서 정보가 없는 모델에 순서를 인식시키기 위한 위치 벡터를 추가함
Feed-Forward Network	각 위치 별로 독립적으로 적용되는 작은 MLP 구조
계층정규화 & Residual 연결	학습의 안정성과 정보의 흐름을 유지하는 역할을 함



Transformer

트랜스포머는

**기본 구조의 한계를 뛰어넘어
다양한 분야로 확장되고 있는 모델**



자연어처리

◇ 문장을 이해하고 생성하는 데 강점을 가지고 있음

예 기계 번역 (T5), 문서 요약 (BART), 질의응답 (BERT), 대화 (GPT)



그 외의 분야

◇ 코드 생성

예 GPT-4o, Gemini, Claude 3

◇ 음성 처리

예 SpeechT5, Whisper

◇ 이미지 생성


예 ViT (Vision Transformer), DINO

◇ 멀티모달

예 CLIP, Flamingo, Gemini, GPT-4o 등



↳ 딥러닝 기반의 기계번역 발전 과정





↳ 딥러닝 기반의 기계번역 발전 과정

