

금융 AI 리터러시

AI 학습을 위한 데이터 전처리 전략



데이터 전처리의 개념





↳ 데이터 전처리란?

데이터 전처리 (Data Preprocessing)

원시 데이터(Raw Data)를 기계학습 알고리즘이 이해하고 학습하기에 적합한 형태로 변환하는 핵심적인 과정



데이터 전처리 (Data Preprocessing)

원시 데이터(Raw Data)를 기계학습 알고리즘이 이해하고 학습하기에 적합한 형태로 변환하는 핵심적인 과정

Garbage in, garbage out



데이터 전처리 (Data Preprocessing)

원시 데이터(Raw Data)를 기계학습 알고리즘이 이해하고 학습하기에 적합한 형태로 변환하는 핵심적인 과정

Garbage in, garbage out

좋은 결과를 좌우하는 것은 데이터의 품질!



↳ 데이터 전처리란?

전처리의 핵심

- ◇ 원시 데이터를 정제 데이터로 가공해야 함
- ◇ 분석 목적에 맞는 형태로 데이터를 변형해야 함
- ◇ 데이터의 품질을 높여 모델의 성능을 끌어 올려야 함

**전처리는 데이터 분석, 데이터 마이닝, 머신러닝 등
데이터 기반의 모든 프로젝트의 필수 단계**



데이터의 품질이 AI 모델에 미치는 영향



저품질 데이터



고품질 데이터

저품질 데이터는 AI의 부정확한 결과와 함께 **신뢰 저하**, **가치 손실**, **법적 리스크**를 초래함



데이터 전처리가 필요한 이유

잡음(Noise)

데이터에 포함된 무작위적인 오류나 불필요한 정보

예 센서 측정 오류로 인한 비정상적인 값

이상치(Outlier)

데이터의 일반적인 패턴에서 크게 벗어나는 값

예 성인 나이 데이터에 '200세'가 입력된 경우

부적합(Inconsistent)

데이터 간의 논리적 모순이나 표현 방식의 불일치

예 주소는 '서울'인데 우편번호는 '부산'인 경우

결측치(Missing Value)

특정 항목의 값이 누락되어 비어 있는 상태

예 고객 정보 테이블에 '연락처'가 없는 경우

중복(Duplicated)

동일한 데이터가 데이터셋 내에 여러 번 반복되는 것

예 동일한 고객 정보가 두 번 이상 기록된 경우



탐색적 데이터 분석 (EDA)

데이터의 특성과 패턴을 파악하고,
전처리 전략을 수립하기 위한 필수적인 과정

데이터 출처 파악

데이터가 어디서, 어떻게 수집되었는지 이해하여
데이터의 신뢰성과 적합성을 평가함

기본 통계량 분석

평균, 중앙값, 표준편차, 분포 등을 확인하여
데이터의 전체적인 특성을 파악함

데이터 분포 시각화

히스토그램, 박스플롯, 산점도 등을 통해
데이터의 분포와 특성을 직관적으로 확인함



탐색적 데이터 분석 (EDA)

데이터의 특성과 패턴을 파악하고,
전처리 전략을 수립하기 위한 필수적인 과정

결측치 및 이상치 탐지

데이터 내 누락된 값과 비정상적인 값을 파악하여
전처리 전략을 수립함

변수 간 상관관계 분석

피어슨 상관계수, 히트맵 등을 활용하여
변수들 간의 관계를 파악하고 특성 선택에 활용함

시간적 패턴 분석

시계열 데이터의 추세, 계절성, 주기성을 확인하여
시간 기반의 특성을 추출함



데이터 정제
(Cleaning)

데이터 변환
(Transformation)

데이터 통합
(Integration)

데이터 축소
(Reduction)

Ai



- ◇ 부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정
- ◇ 결측치 처리, 이상치 제거, 중복 데이터 제거, 오류 수정 등을 포함함

데이터 정제
(Cleaning)

데이터 변환
(Transformation)

데이터 통합
(Integration)

데이터 축소
(Reduction)

Ai



- ◇ 부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정
- ◇ 결측치 처리, 이상치 제거, 중복 데이터 제거, 오류 수정 등을 포함함

데이터 정제
(Cleaning)

데이터 변환
(Transformation)

- ◇ 모델이 데이터를 더 쉽게 이해하고 패턴을 학습할 수 있도록 데이터의 구조나 형식을 바꾸는 과정
- ◇ 스케일링, 인코딩, 분포 변환, 특성 공학 등을 포함함

데이터 통합
(Integration)

데이터 축소
(Reduction)

Ai



데이터 전처리 요소

- ◆ 부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정
- ◆ 결측치 처리, 이상치 제거, 중복 데이터 제거, 오류 수정 등을 포함함
- ◆ 여러 다른 소스에 흩어져 있는 데이터를 하나의 일관된 데이터셋으로 결합하는 과정
- ◆ 다양한 소스 병합, 데이터 조인, 스키마 정렬 및 중복 해결 등을 포함함

데이터 정제
(Cleaning)

데이터 변환
(Transformation)

데이터 통합
(Integration)

데이터 축소
(Reduction)

- ◆ 모델이 데이터를 더 쉽게 이해하고 패턴을 학습할 수 있도록 데이터의 구조나 형식을 바꾸는 과정
- ◆ 스케일링, 인코딩, 분포 변환, 특성 공학 등을 포함함

Ai



데이터 전처리 요소

- ◆ 부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정
- ◆ 결측치 처리, 이상치 제거, 중복 데이터 제거, 오류 수정 등을 포함함
- ◆ 여러 다른 소스에 흩어져 있는 데이터를 하나의 일관된 데이터셋으로 결합하는 과정
- ◆ 다양한 소스 병합, 데이터 조인, 스키마 정렬 및 중복 해결 등을 포함함

데이터 정제
(Cleaning)

데이터 변환
(Transformation)

데이터 통합
(Integration)

데이터 축소
(Reduction)

- ◆ 모델이 데이터를 더 쉽게 이해하고 패턴을 학습할 수 있도록 데이터의 구조나 형식을 바꾸는 과정
- ◆ 스케일링, 인코딩, 분포 변환, 특성 공학 등을 포함함
- ◆ 데이터의 양이나 차원을 줄이는 동시에 분석에 필요한 핵심 정보는 최대한 유지하는 과정
- ◆ 차원 축소, 특성 선택, 데이터 샘플링, 데이터 압축 등을 포함함



부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정

1 결측치 처리

2 이상치 제거

3 중복 데이터 제거

4 데이터의 형식 통일

비어 있는 값(NaN, Null)을 처리하는 방법

처리 방법

- ◆ 삭제: 결측값이 포함된 행 또는 열 제거
- ◆ 대체: 평균, 중앙값, 최빈값 등의 통계치 사용
- ◆ 예측 기반: 다른 변수를 기반으로 한 예측값 생성
- ◆ 유형: MCAR, MAR, MNAR에 따른 다른 전략 적용



부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정

1 결측치 처리

2 이상치 제거

3 중복 데이터 제거

4 데이터의 형식 통일

일반적인 패턴에서 벗어난 값의 탐지 및 처리

제거 방법

- ◇ 통계적 기법: Z-score, IQR(사분위수 범위) 활용
- ◇ 도메인 지식: 해당 분야의 전문 지식을 활용한 판단
- ◇ 다양한 처리 방법이 있음
 - 예 제거, 대체, 별도 범주화, 변환 등



부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정

1 결측치 처리

2 이상치 제거

3 **중복 데이터 제거**

4 데이터의 형식 통일

동일한 데이터의 식별 및 제거

중복 종류

- ◇ 완전 중복: 모든 필드가 일치하는 중복
- ◇ 부분 중복: 핵심 식별자가 일치하는 중복



부정확하거나 불완전한 데이터를 식별·수정·제거하는 과정

1 결측치 처리

2 이상치 제거

3 중복 데이터 제거

4 데이터의 형식 통일

날짜, 숫자, 문자열 형식 표기법의 통일



데이터 변환

정규화와 표준화, 범주형 데이터 인코딩

정규화 (Normalization)

- ◇ 모든 특성 값을 동일한 범위로 바꾸는 작업
- ◇ 일반적으로 0과 1 사이의 범위로 변환함
- ◇ 데이터의 분포를 모르거나 KNN, 신경망처럼 분포에 민감하지 않은 모델을 사용할 때 유용함

표준화 (Standardization)

- ◇ 데이터의 통계량을 동일하게 맞추는 작업으로, 평균은 0, 표준편차를 1로 만듦
- ◇ 데이터가 정규분포를 따를 때 가장 효과적이고 이상치에 덜 민감함
- ◇ 선형 회귀, 로지스틱 회귀, SVM 등의 모델에 적합함



데이터 변환

정규화와 표준화, 범주형 데이터 인코딩

정규화 (Normalization)

- ◇ 모든 특성 값을 동일한 범위로 바꾸는 작업
- ◇ 일반적으로 0과 1 사이의 범위로 변환함
- ◇ 데이터의 분포를 모르거나 KNN, 신경망처럼 분포에 민감하지 않은 모델을 사용할 때 유용함

표준화 (Standardization)

- ◇ 데이터의 통계량을 동일하게 맞추는 작업으로, 평균은 0, 표준편차를 1로 만듦
- ◇ 데이터가 정규분포를 따를 때 가장 효과적이고 이상치에 덜 민감함
- ◇ 선형 회귀, 로지스틱 회귀, SVM 등의 모델에 적합함

스케일 정렬이 목적



데이터 변환

정규화와 표준화, 범주형 데이터 인코딩

정규화 (Normalization)

- ◇ 모든 특성 값을 동일한 범위로 바꾸는 작업
- ◇ 일반적으로 0과 1 사이의 범위로 변환함
- ◇ 데이터의 분포를 모르거나 KNN, 신경망처럼 분포에 민감하지 않은 모델을 사용할 때 유용함

표준화 (Standardization)

- ◇ 데이터의 통계량을 동일하게 맞추는 작업으로, 평균은 0, 표준편차를 1로 만듦
- ◇ 데이터가 정규분포를 따를 때 가장 효과적이고 이상치에 덜 민감함
- ◇ 선형 회귀, 로지스틱 회귀, SVM 등의 모델에 적합함

분포를 통일시키는 작업



데이터변환

정규화와 표준화, 범주형 데이터 인코딩

범주형 데이터 인코딩

1 레이블 인코딩

2 원-핫 인코딩

3 타겟 · 빈도 인코딩

순서가 있는 범주형 데이터(Ordinal data)를
고유한 정수로 변환하는 작업

적용 사례

- ◇ 순서가 있는 데이터에 적합함
- ◇ 교육 수준, 만족도 등급, 제품 등급 등에 활용됨



데이터 변환

정규화와 표준화, 범주형 데이터 인코딩

범주형 데이터 인코딩

1 레이블 인코딩

2 원-핫 인코딩

3 타겟 · 빈도 인코딩

순서가 없는 범주형 데이터(Nominal data)를
0과 1로 구성된 벡터로 변환하는 작업

적용 사례

- ◇ 순서가 없는 데이터에 적합함
- ◇ 국가, 색상, 브랜드, 직업 등에 활용됨



데이터변환

정규화와 표준화, 범주형 데이터 인코딩

범주형 데이터 인코딩

1 레이블 인코딩

2 원-핫 인코딩

3 타겟 · 빈도 인코딩

카테고리가 많은 고차원(High-Cardinality) 데이터에
유용한 인코딩 방법

적용 사례

- ◇ 타겟 인코딩
: 각 카테고리를 타겟 변수의 평균값으로 대체
- ◇ 빈도 인코딩
: 카테고리를 데이터셋 내 빈도수로 대체



정규화와 표준화

- ◇ 수치형 변수의 스케일을 맞춰주는 작업으로, 정규화는 동일한 범위로 맞춰주는 작업이며 표준화는 통계량을 동일하게 맞춰주는 작업

인코딩


- ◇ 범주형 변수를 모델이 이해할 수 있도록 숫자로 바꿔주는 작업

**데이터 변환에서 기초 작업으로
모델 성능 향상, 과적합 및 정보 손실 방지 가능!**



데이터 조인 (Data Join)

공통된 키(key)를 기준으로
여러 데이터셋을 논리적으로 연결하는 방식





데이터 조인 (Data Join)

공통된 키(key)를 기준으로
여러 데이터셋을 논리적으로 연결하는 방식

데이터 통합 시 주의 사항

스키마 정렬

변수명을 통일하여 데이터의 일관성을 유지해야 함

중복 해결

중복 데이터를 식별하고 제거해야 함

메타데이터 관리

통합된 데이터의 출처와 변환 이력을 추적해야 함



데이터 축소 전략

차원 축소

데이터의 분산을 최대한 보존하면서,
새로운 축으로 데이터를 투영해서 차원을 줄이는 기법

예 PCA, t-SNE, UMAP 등

특성 선택

모델 성능에 가장 큰 영향을 미치는 중요한 변수들만 선택하고,
관련성이 낮은 변수는 제거하는 기법

예 필터 방식, 래퍼 방식, 임베디드 방식 등

샘플링

데이터가 너무 많을 경우 일부만 추출하여 분석하는 기법

예 랜덤 샘플링, 계층 샘플링, 오버 샘플링, 언더 샘플링

데이터 압축

원본 데이터의 의미를 유지하면서 저장 공간을 절약하는 기법

데이터 전처리 기법과 특성 공학





특성 공학

(Feature Engineering)

공통된 키(key)를 기준으로

여러 데이터셋을 논리적으로 연결하는 방식

**데이터를 정제하는 것을 넘어
모델이 잘 학습할 수 있도록
특성을 ‘설계’하는 과정**



특성 공학

(Feature Engineering)

공통된 키(key)를 기준으로

여러 데이터셋을 논리적으로 연결하는 방식

**데이터를 정제하는 것을 넘어
모델이 잘 학습할 수 있도록
특성을 ‘설계’하는 과정**

모델보다 특성(Feature)이 성능을 만듦



특성 생성(Feature Creation)

- ◇ 기존 데이터에서 새로운 특성을 만들어내는 과정
- ◇ 파생 변수를 생성함
- 예 '수익'과 '비용' 컬럼을 활용하여 '순이익' 컬럼 생성,
'키'와 '몸무게'를 'BMI'라는 건강지표 생성 등



특성 변환(Feature Transformation)

- ◇ 특성을 모델이 더 잘 이해할 수 있는 형태로 변환하는 과정
- ◇ 특성을 재가공한다는 점에서 목적 지향적인 특징을 가지고 있음
- 예 스케일링, 로그 변환, 범주형 데이터 인코딩 등



특성 선택(Feature Selection)

- ◇ 모델에 가장 중요한 특성들만 선택하는 전략
- ◇ 성능향상과 과적합 방지의 목적으로 특성 선택 작업을 함

필터 방식

통계적 방법으로 모델과 독립적으로 특성을 선택하는 방식

래퍼 방식

모델 성능 기반으로 특성의 조합을 찾는 방식

임베디드 방식

모델 학습 자체에 특성 선택이 포함되어 있는 경우에 활용되는 방식

- ◇ 특성 선택은 모델의 간결성, 해석 용이성, 성능 향상을 가능하게 함



특성 추출(Feature Extraction)

- ◇ 기존의 특성을 조합하여 새로운 특성으로 압축하는 과정
- ◇ 수학적이고 추상적인 접근

주성분 분석(PCA)

데이터의 정보를 유지하며 핵심 변수로 차원을 축소하는 방식

선형 판별 분석(LDA)

클래스 구분을 극대화하여 분류 성능을 높이는 차원 축소 기법

오토인코더 (Auto Incoder)

데이터의 압축 및 복원 과정에서 잠재 변수(Latent Variable)를 추출해 새로운 특성으로 사용하는 방식

- ◇ 성능을 극대화하지만 해석이 어렵다는 단점이 있음



특성 선택과 특성 추출

- ◇ 원본 특성 중 가장 유용한 부분집합을 선택함
- ◇ 원본의 특성을 그대로 유지함
- ◇ 선택된 변수의 의미가 명확하여 해석 가능성이 높음
- ◇ 선택되지 않은 특성의 정보는 완전히 손실됨

특성 선택

Feature Selection

- ◇ 원본의 특성을 조합 및 변환하여 새로운 특성을 생성함
- ◇ 원본 특성이 새로운 특성으로 변환됨
- ◇ 새로 생성된 변수의 의미가 모호할 수 있음
- ◇ 저차원으로 변환 시 일부 정보가 손실되지만 전체 특성의 정보를 압축함

특성 추출

Feature Extraction



특성 선택과 특성 추출

- ◇ 원본 특성 중 가장 유용한 부분집합을 선택함
- ◇ 원본의 특성을 그대로 유지함
- ◇ 선택된 변수의 의미가 명확하여 해석 가능성이 높음
- ◇ 선택되지 않은 특성의 정보는 완전히 손실됨

특성 선택

Feature Selection

**모델의 해석과
개별 변수의 영향력을 이해해야 할 때**

- ◇ 원본의 특성을 조합 및 변환하여 새로운 특성을 생성함
- ◇ 원본 특성이 새로운 특성으로 변환됨
- ◇ 새로 생성된 변수의 의미가 모호할 수 있음
- ◇ 저차원으로 변환 시 일부 정보가 손실되지만 전체 특성의 정보를 압축함

특성 추출

Feature Extraction



특성 선택과 특성 추출

- ◇ 원본 특성 중 가장 유용한 부분집합을 선택함
- ◇ 원본의 특성을 그대로 유지함
- ◇ 선택된 변수의 의미가 명확하여 해석 가능성이 높음
- ◇ 선택되지 않은 특성의 정보는 완전히 손실됨

특성 선택

Feature Selection

- ◇ 원본의 특성을 조합 및 변환하여 새로운 특성을 생성함
- ◇ 원본 특성이 새로운 특성으로 변환됨
- ◇ 새로 생성된 변수의 의미가 모호할 수 있음
- ◇ 저차원으로 변환 시 일부 정보가 손실되지만 전체 특성의 정보를 압축함

특성 추출

Feature Extraction

예측 성능의 극대화가 목표일 때



텍스트 데이터 전처리 과정

정제 및 정규화

- ◇ HTML 태그 제거
- ◇ 특수 문자 제거
- ◇ 대소문자 통일
- ◇ 공백 정규화

토큰화

텍스트를 의미 단위로
쪼개는 작업

불용어 제거

분석에 불필요한
조사·접속사 같은 단어

어간 및 표제어 추출

- ◇ 어간 추출은
빠른 추출이 가능함
- ◇ 표제어 추출은
정확한 추출이
가능함

벡터화

- ◇ Bag-of-Words(BoW)
- ◇ TF-IDF
- ◇ 워드 임베딩



텍스트 데이터는 **비정형 데이터**로,
형태가 자유롭고 규칙이 없어
모델이 그대로 이해할 수 없음

숫자 벡터 형태의 변환 작업이 필수적임



텍스트 데이터 전처리 과정

정제 및 정규화

- ◇ HTML 태그 제거
- ◇ 특수 문자 제거
- ◇ 대소문자 통일
- ◇ 공백 정규화

토큰화

텍스트를 의미 단위로
쪼개는 작업

불용어 제거

분석에 불필요한
조사·접속사 같은 단어

어간 및 표제어 추출

- ◇ 어간 추출은
빠른 추출이 가능함
- ◇ 표제어 추출은
정확한 추출이
가능함

벡터화

- ◇ Bag-of-Words(BoW)
- ◇ TF-IDF
- ◇ 워드 임베딩



Time Series Data

텍스트 전처리는

**“자유로운 문장을 컴퓨터가 이해할 수 있는
숫자 형태로 바꾸는 과정”**



시계열 데이터

결측치 처리

리샘플링

정상성 확보

특성 생성

Ai



시계열 데이터

- ◇ 누락된 지점의 앞뒤 데이터를 사용하여 값을 추정하는 보간법을 사용할 수 있음
- ◇ 직전 값이나 직후 값으로 대체하는 방법도 있음
- ◇ 평균이나 중앙값은 시간의 흐름을 무시하기 때문에 주의하여 사용해야 함

결측치 처리

리샘플링

정상성 확보

특성 생성

Ai



시계열 데이터

결측치 처리

리샘플링

정상성 확보

특성 생성

- ◇ 데이터의 시간 간격을 조정하는 작업
- ◇ 짧은 시간 단위로 데이터를 늘리는 업샘플링과 긴 시간 단위로 집계하여 노이즈를 줄이는 데 효과적인 다운샘플링으로 나뉨

Ai



시계열 데이터

결측치 처리

리샘플링

정상성 확보

특성 생성

- ◇ 평균과 분산이 시간에 따라 크게 변하지 않아야 한다는 '정상성'의 특징을 가지고 있다고 가정함
- ◇ 차분이나 로그 변환을 통해 시간 흐름에 따른 변동성을 조절함

Ai



시계열 데이터

결측치 처리

리샘플

정상성 확보

특성 생성

- ◇ 날짜에서 세부 특징을 뽑아내는 시간 기반의 특성
- ◇ 단기 변동성을 완화하고 장기 추세를 파악하는 이동 평균
- ◇ 이전 시점의 값을 현재 시점의 특성으로 활용하는 시차 특성



Time Series Data

시계열 데이터의 핵심은 시간의 흐름을 보존하고 활용하는 것



이미지 데이터 (Image Data)

텍스트나 숫자와 달리 픽셀 형태의 시각적 데이터로,
다른 데이터와 전처리 과정을 다르게 접근해야 함

- ◇ 크기 조절
- ◇ 정규화
- ◇ 데이터 증강



이미지 조절(Image Resizing)

- ◇ 모든 이미지의 크기를 모델의 입력 요구사항에 맞게 동일하게 조정하여 AI 모델의 안정적인 학습이 가능하게 함
- ◇ 이미지 조절로 인한 왜곡이나 정보 손실을 방지에 주의하여야 함

정규화(Normalization)

- ◇ 학습 속도 향상 및 안정적인 학습 도모하기 위해 정규화를 활용함
- ◇ 픽셀 값을 일정한 범위로 조정하여 모델의 학습을 안정화함



데이터 증강(Data Augmentation)

- ◇ 모델의 일반화 성능을 높이고 과적합을 막기 위해 사용함
- ◇ 기존 이미지에 변형을 가해 학습 데이터의 양을 인위적으로 늘림
- 예 기하학적 변환: 이미지 회전, 상하좌우 반전, 확대 및 축소, 이동, 자르기 등
색상 변환: 밝기, 대비, 채도 조절 등



Q

이미지 전처리는
어떤 효과가 있을까?

모델의 학습 속도 향상
예측의 정확도 향상
과적합 위험 감소

금융 데이터 전처리와 실무 적용 전략





금융 데이터

높은 불확실성과 복잡성을 지니고

외부 요인의 영향을 받는 구조



분석 및 모델링 시 특별한 접근이 필요함



높은 노이즈와 낮은 신호 대비 잡음비

실제 추세(신호)보다 시장 참여자의 심리, 뉴스 등의
무작위적 변동(노이즈)이 훨씬 많기 때문에 유의미한 패턴을 찾기 어려움

비정상성(Non-Stationarity)

금융 데이터는 시간의 흐름에 따라 통계적 특성이 계속해서 변화하여
과거 데이터로 학습한 모델이 미래를 정확히 예측하기 어려운 주된 요인이 됨



자기상관성 및 다중공선성

오늘의 가격이 어제의 가격에 영향을 받는 등
데이터가 시간적으로 강한 상관관계를 가지며,
주가, 환율, 금리 등 여러 변수들이 서로 밀접하게 연관되어 움직임

외부 사건의 영향

예측 불가능한 외부 사건에 매우 민감하게 반응하여
갑작스럽게 시장의 추세를 바꿈

예 금리 결정, 지정학적 리스크, 팬데믹 등



금융 데이터는

**불확실성이 크고, 시간에 따라 특성이 바뀌며,
변수 간 연관성이 복잡하고, 외부 환경에 민감함**



금융 데이터 전처리는 도메인에 대한 이해가 필수적임



불균형 데이터 (Imbalanced Data)

관심 있는 특정 클래스(사건)가 다른 클래스에 비해 압도적으로 적게 나타나는 데이터를 의미함

- 예) 사기 거래 0.1% 미만의 신용 사기 탐지,
소수의 부도로 인한 대출 부도 예측
극단적 변동에 의한 주가의 급등·급락 예측

**정확도는 높지만 소수의 중요 클래스를 탐지하지 못하는
쓸모 없는 모델이 됨**



해결 방안

데이터 레벨
접근법

알고리즘 레벨
접근법

Ai



해결 방안

데이터 레벨
접근법

데이터 자체를 조작하여
균형을 맞추는 방식

알고리즘 레벨
접근법

Ai



데이터 레벨 접근법

언더샘플링 (Undersampling)

다수 클래스의 데이터를 일부 줄여서 소수 클래스와 균형을 맞추는 방법으로, 간단하고 빠르지만 정보 손실의 위험이 있음

오버샘플링 (Oversampling)

소수 클래스의 데이터를 인위적으로 늘리는 방법

예 SMOTE 기법

복합샘플링 (Combined Sampling)

언더샘플링과 오버샘플링을 조합하여 사용하는 샘플링 방법

예 SMOTE 기법으로 소수 클래스를 늘리고 Tomek Links로 다수 클래스를 정리하는 방식



해결 방안

데이터 레벨
접근법

알고리즘 레벨
접근법

데이터를 직접 건드리지 않고
모델이 학습할 때
불균형을 고려하도록
설정하는 방식

Ai



알고리즘 레벨 접근법

비용 민감 학습

(Cost-sensitive learning)

소수 클래스 오분류에 대해 더 큰 패널티를 부여하는 방법

앙상블 기법

(Ensemble)

소수 클래스의 데이터를 인위적으로 늘리는 방법



평가 지표

정밀도(Precision)

재현율(Recall)

F1-Score

AUC-ROC

단순히 정확도(Accuracy)로만 모델을 평가하는 것이 아닌
구조를 바꾸거나 학습 방식을 조정하여 **현실적인 성능을 판단하는 것이 중요함**



데이터 익명화

데이터의 유용성은 유지하면서 개인을 식별할 수 없도록 만드는 과정

가명처리 (Pseudonymization)

개인 식별 정보를 다른 값으로 대체하는 방식으로
추가 정보와 결합 시 재식별 위험이 존재함

총계처리/범주화 (Generalization)

데이터를 더 큰 범위의 그룹으로 묶어 일반화 하는 방식

데이터 마스킹 (Data Masking)

중요 정보의 일부 또는 전체를 별표(*) 등으로 가리는 방식

잡음 추가 (Noise Addition)


원본 데이터에 통계적 잡음을 추가하여 개별 값을 약간씩 변경함으로써
원본 값 추정을 어렵게 하고, 통계적 특성은 유지하면서 개인정보를 보호함

차분 프라이버시 (Differential Privacy)

데이터 분석 결과 자체의 프라이버시를 보장하는 강력한 보호 모델로,
데이터셋에 특정 개인이 포함되었는지 여부를 알 수 없도록 조치함



원본 데이터



- ◇ 홍길동
- ◇ 35세
- ◇ 서울시 강남구 역삼동
- ◇ 010-1234-5678


익명화 데이터



- ◇ 사용자_1
- ◇ 30대
- ◇ 서울시 강남구
- ◇ 010-****-5678




원본 데이터



- ◇ 홍길동
- ◇ 35세
- ◇ 서울시 강남구

익명화 데이터



- ◇ 사용자_1
- ◇ 30대
- ◇ 010-****-5678

익명화는 데이터의 유용성과 프라이버시 간의 균형을 맞추는 일!



합성 데이터
(Synthetic Data)

실제 데이터와 통계적 특성이 유사하여, 실제 데이터 분석 결과와 유사한 결과를 얻을 수 있도록 새롭게 생성해 낸 가상의 데이터

안전성

개인 식별 정보 없이 안전하게 데이터의 공유 및 분석이 가능함

유연성

다양한 유형과 조건의 데이터 생성이 가능함

재현성

동일한 특성의 데이터를 반복하여 생성이 가능함

비용 효과성

데이터 수집의 비용을 절감할 수 있음



합성 데이터의 구축 과정





전략 수립 시 고려사항

◇ 데이터 도메인의 특성

: 데이터가 생성된 특성 산업에 대한 이해가 필수적임

예 금융, 의료, 제조 등

◇ 프로젝트의 목적

: 프로젝트 목표에 따라 해석력과 예측력 중심의 전략을 달리 해야 함

예 의료 진단과 같이 설명 가능성이 중요한 데이터는 특성 선택을 우선적으로 고려해야 함
고객 이탈 예측과 같이 성능이 중요한 데이터는 특성 추출이나 복잡한 파생 생성이 효과적일 수 있음

◇ 전처리 단계별 우선순위 조정

: 전처리는 결측·이상치 처리 → 특성 변환·스케일링 → 특성 선택·생성 순으로 진행하되,
데이터의 상태나 유형에 따라 유연하게 조정해야 함



전략 수립 시 고려사항

◇ 데이터 유형별 전처리 전략

- 1 이미지: 크기 통일 → 픽셀 정규화 → 회전이나 반전 등의 데이터 증강으로 일반화 성능 향상
- 2 텍스트: 비정형 텍스트를 최소 단위로 토큰화 → 불용어 제거 → 숫자를 벡터로 변환하는 임베딩
- 3 시계열: 데이터의 시간을 맞추는 리샘플링 → 통계적 특성을 일정하게 만드는 정상성 확보 → '월', '요일' 등을 추출하는 시간 기반 특성 생성



좋은 AI 모델은 좋은 데이터에서 시작되고



**좋은 데이터는
전략적인 전처리에서 만들어진다!**